华东师范大学数据学院上机实践报告

课程名称: 信息检索 年级: 2018 上机实践成绩: 指导教师: 张蓉 姓名: 孙秋实

上机实践名称: 支持统配查询处理的检索系统 学号: 10185501402 上机实践日期: 2021/11/15

Part 1

实验目的

(1) 为文档构建倒排索引

(2) 实现支持统配查询处理的检索系统

Part 2

实验任务

- (1) 在单机伪分布式下使用 Spark 为文档数据集构建倒排索引
- (2) 建立轮排索引
- (3) 构建支持统配查询处理的检索系统
- (4) 对结果进行分析和展示

Part 3

使用环境

- (1) Google Colab
- (2) Python 3.7
- (3) Spark 3.2.0
- (4) Scala 2.12
- (5) Idea 2020.02.03

Part 4

实验过程

Section 1

轮排索引与通配查询

在本次实验中涉及轮排索引概念,使用 \$ 是一个特殊字符,来标记词的结尾,随后为单词建立轮排表。如图 1 所示,为单词 hello 建立轮排。




图 1: Permuterm indexes

以下代码片段是轮排的简单实现

```
# simple demo of permuterm
word = 'hellworld'
word += '$'
for i in range(len(word)):
    print('permute:',i,word)
    word = word[-1]+word[:-1]
```


输出为

permute: 0 hellworld\$
permute: 1 \$hellworld
permute: 2 d\$hellworl
permute: 3 ld\$hellwor
permute: 4 rld\$hellwo
permute: 5 orld\$hellw

. . .

在之前的实验中实现了布尔查询,本次实现的通配查询在输入的形式上更加多样,可以支持以下种类的查询:

- *aaa, 如 *ent: 代表所有包含以 ent 结尾的词项的文档
- bbb*, 如 mon*: 代表所有包含以 mon 开头的词项的文档
- *ccc*, 如 *hel*: 代表所有包含中间部分有 hel 的词项的文档
- dd*ee,如 map*duce:代表所有包含以 map 开头,duce 结尾的词项的文档
- * 是一个特殊字符,代表着查询时从这里"切分"



► Figure 3.4 Example of a postings list in a 3-gram index. Here the 3-gram etr is illustrated. Matching vocabulary terms are lexicographically ordered in the postings.

图 2: Index-Vocab Matching

如图 2 所示, 我们需要对切分好的片段进行匹配。

Section 2

倒排索引的 Spark 实现

本次实验使用与 Project2 中一样的方式倒排索引,同样是生成 dict.index.txt,因为之前的实验已经涉及,所以此处简要略过,具体内容可见 Project2 的倒排索引实现。

*Spark3.2.0 + Scala2.12

```
object ReadGetIndex {
// val writer = new PrintWriter(new File("spark_index_test.txt" ))
 def main(args: Array[String]): Unit = {
   //get Spark Session
   val spark = SparkSession.builder().appName("Information-Retrieval-Project2")
     .master("local")
     .getOrCreate()
   //Get Dir
   val document_source = spark.sparkContext.wholeTextFiles("src/data-2500")
   //Get File Name
   val res = document_source.flatMap{ x =>
     val doc = x._1
      .split(s"/")
      .last // get file name.txt
      .split("\\.")
      .head // get file name
     x._2.split("\r\n") //seperate -> line -> blank
       .flatMap(\_.split(" ").map { y => (y, doc)})
       .groupByKey.map{case(x,y)=>(x,y.toSet.mkString(","))} // mkstring即用指定字符串分隔
   // pattern matching
   // 此处需要注意partition!
   res.coalesce(1).saveAsTextFile("spark_index_test.txt")
   res.foreach(println)
 }
}
```

Section 3

B-Tree

本次实验使用 Python 的 BTrees 库

```
from BTrees.OOBTree import OOBTree

BTree_index = OOBTree() # 初始化一个BTree对象
```

随后将轮排结果插入 BTree, 获得轮排的方式与前面的 Demo 一致

```
def Permuterm_Insert(BTree_index,key,word):
    word += '$'
    for i in range(len(word)):
        BTree_index.update({word:key})
```

```
# 插入Key-Value Pair
word = word[-1]+word[:-1]
```

Section 4

通配搜索系统的构建

在搜索时候, 需要将输入的查询分为两种

- *aaa, 如 *ent: 代表所有包含以 ent 结尾的词项的文档
- bbb*, 如 mon*: 代表所有包含以 mon 开头的词项的文档
- *ccc*, 如 *hel*: 代表所有包含中间部分有 hel 的词项的文档

它们在去除匹配符后只有一个 token

• dd*ee,如 map*duce:代表所有包含以 map 开头,duce 结尾的词项的文档

这种情况下,去除匹配符后会有两个 tokens 分类讨论进行查询,代码如下

```
def Permuterm_Search(BTree_index,raw_word):
   ans = []
   # insert$
   raw word += '$'
   word_sep = raw_word.split('*')
   if len(word_sep) == 1:
       ans_idx = Word_Search(BTree_index,word_sep[0])
   else:
      target = word_sep[1] + word_sep[0]
       ans_idx = Word_Search(BTree_index, target)
   ans_idx = sorted(ans_idx, key = lambda x: x[1]) # 排序
   ans = []
   # get top 2 data
   for i in ans_idx[:2]:
       ans = SearchOR(ans, dic[i[0]])
   ansWord = [x[1] for x in ans_idx]
   return ans, ansWord
```

最后使用一个 While 循环启动查询(配备适当的退出条件),根据输入完成不同类型的查询需求 根据实验手册的要求,输出

- 按照字典序输出的所有词项
- 以字典序前 2 个词项作输入,查询后获得的 DocID 并集

```
while (True):
    query = input('输入通配查询').split()
    print('Query',query)
    Doc_id_ans, Word_ans = Permuterm_Search(BTree_index, query[0])
```

Section 5

查询演示

在此部分做查询的演示

• 实现单个关键词查询

```
輸入通配查询 *sment
Query ['*sment']
['assessment', 'embarrassment', 'harassment', 'office_of_technology_assessment', 'radiological—assessment', 'reassessment', 'self—ass
essment']
DocID: [1077, 1141, 1144, 1166, 1246, 1294, 1314, 1477, 1498, 1593, 1629, 1637, 1702, 1767, 1770, 1792, 1871, 1920, 1940, 2102, 2124,
2218, 2255, 2263, 2303, 2359, 4414, 8477, 10221, 10869, 13966, 17498, 17901, 18425, 18983, 19759, 20193, 20276, 21062, 21576, 22351,
22703, 22850, 23516, 23538, 23610, 23922, 24935, 24837, 24999, 25003, 25614, 25671, 25683, 25705, 26369, 26519, 27429, 27430, 27549,
27648, 28591, 28931, 31024, 31031, 32373, 32513, 32668, 33161, 34353, 36063, 36064, 36126, 36429, 37897, 37909, 38251, 39951, 39951,
40003, 40077, 40168, 40275, 40310, 40517, 41804, 42304, 42378, 42604, 43799, 46769, 47509, 50354, 52230, 53403, 53742, 54079, 55261,
55715, 55847, 56409, 57319, 57328, 57333, 58347, 60504, 61548, 61587, 61651, 61661, 61661, 61672, 61627, 61824, 64341, 64342, 65233, 65316,
65468, 65670, 65718, 65839, 65842, 67912, 67942, 68196, 68203, 68261, 68262, 68268, 68359, 68360, 68451, 68470, 68513, 68516, 68648,
68732, 68869, 71625, 71700, 74213, 74249, 74544, 74723, 74835, 75628, 76113, 77715, 79512, 80272, 81248, 81292, 81471, 81700, 80207,
82049, 82643, 82775, 82959, 83049, 83432, 84164, 86264, 88372, 88815, 90889, 91753, 92406, 92603, 92610, 92921, 92927, 93875, 93987,
93988, 94008, 95664, 96143, 96499, 96993, 97982]
```

图 3: 单侧匹配查询(左侧)

可以使用连续查询

图 4: 单侧匹配查询(右侧)

图 5: 中间匹配查询

华东师范大学数据科学与工程学院学生实验报告

最后是对匹配单词的中间字段进行查询

```
輸入通配音询 *sment*
['ssment*']
['assessment', 'assessments', 'embarrassment', 'embarrassments', 'harassment', 'office_of_technology_assessment', 'radiological-asses sment', 'reassessment', 'self-assessment', 'legorial (1077, 1141, 1144, 1166, 1246, 1294, 1314, 1477, 1498, 1593, 1601, 1629, 1637, 1639, 1702, 1767, 1770, 1792, 1871, 1920, 1940, 2102, 2124, 2218, 2227, 2255, 2263, 2265, 2303, 2359, 4414, 8477, 9159, 9531, 9904, 10764, 10776, 10800, 10812, 11936, 13341, 13903, 13966, 17498, 17901, 18425, 18983, 19759, 20193, 21576, 22703, 22850, 23538, 23922, 24395, 24999, 25003, 25614, 25639, 25664, 25671, 25683, 25705, 26369, 26519, 26644, 27429, 27648, 28591, 28931, 29120, 30994, 31024, 32373, 32668, 34533, 36063, 36064, 36200, 36276, 36249, 36903, 37260, 37897, 37909, 39051, 39656, 39703, 40003, 40077, 40275, 40485, 40517, 41804, 42304, 42378, 42604, 46769, 47509, 48893, 50334, 56033, 51502, 52230, 53403, 54079, 54117, 55261, 56409, 57319, 57325, 57323, 57332, 57323, 57382, 57394, 58850, 66504, 61101, 61548, 61552, 61564, 61587, 61651, 61661, 61669, 61672, 61824, 62077, 64341, 64342, 65233, 65316, 65468, 65474, 65477, 65670, 65718, 65740, 65846, 65846, 65846, 65846, 65846, 65846, 65846, 65846, 65847, 67912, 67942, 60806, 68196, 68103, 68203, 68261, 68262, 68268, 68350, 68360, 68451, 68470, 68513, 68516, 68545, 68648, 68732, 68869, 71625, 71700, 74213, 74249, 74544, 74723, 74835, 75628, 76109, 76113, 79512, 80272, 81248, 81292, 81318, 81471, 81700, 82027, 82029, 82049, 82065, 82643, 82775, 82959, 83047, 83049, 84164, 84912, 84917, 84951, 86264, 88815, 90889, 91753, 92603, 92653, 93692, 94008, 94530, 94536, 95664, 96143, 96298, 96315, 96499, 99379]
```

图 6: 两侧匹配查询

以上为查询系统的四种不同类型查询的结果。